OSTRAVSKÁ UNIVERZITA

PŘÍRODOVĚDECKÁ FAKULTA

KATEDRA INFORMATIKY A POČÍTAČŮ

Predikce kvality vína pomocí hlubokého učení

Experimentální porovnání vlastní neuronové sítě MLP a předtrénovaného modelu TabPFN-2.5

Semestrální projekt
Úvod do Deep Learningu

2026 Anna Ponczová

Abstrakt

Tato práce se zabývá predikcí kvality vína na základě jeho fyzikálně-chemických vlastností s využitím metod hlubokého učení. Cílem je navrhnout a natrénovat vlastní neuronovou síť a porovnat její výsledky s moderním předtrénovaným modelem. Pro experimenty byla použita datová sada Wine Quality obsahující po odstranění duplicit 5 320 záznamů červených a bílých vín.

V rámci projektu byla implementována vícevrstvá neuronová síť MLP v knihovně PyTorch a využit předtrénovaný model TabPFN-2.5. Výsledky byly porovnány s jednoduchým výchozím modelem a algoritmem KNN. Experimentální část zahrnovala hledání vhodných hyperparametrů, analýzu vlivu architektury sítě a množství trénovacích dat i ověření stability výsledků při různých náhodných inicializacích.

Kvalita predikcí byla vyhodnocena pomocí metrik MAE a RMSE. Nejnižší chyby na testovacích datech dosáhl model TabPFN-2.5, následovaný souborem tří neuronových sítí MLP. Výsledky ukazují možnosti využití hlubokého učení při predikci kvality vína a poukazují na význam systematického experimentování.

Klíčová slova: hluboké učení, kvalita vína, neuronová síť MLP, TabPFN, regresní analýza, PyTorch

Obsah

Úvod **3**

1 Data a jejich předzpracování **4**
1.1 Popis datové sady 4
1.2 Explorační analýza dat 4
1.3 Rozdělení dat a standardizace 4

2 Použité modely **5**
2.1 Baseline a model KNN 5
2.2 Vlastní neuronová síť MLP 5
2.3 Předtrénovaný model TabPFN-2.5 6

3 Metodika trénování a experimentů **6**
3.1 Ztrátová funkce a optimalizace 6
3.2 Hledání hyperparametrů 7
3.3 Cílené experimenty a opakovatelnost 7

4 Výsledky a vyhodnocení **8**
4.1 Porovnání predikční kvality 8
4.2 Statistické vyhodnocení 10
4.3 Výpočetní náročnost a analýza chyb 10
4.4 Využití generativní umělé inteligence 11

5 Diskuse **11**

Závěr **12**

Literatura **13**

Seznam obrázků **13**

Seznam tabulek **13**

Úvod

Hodnocení kvality vína představuje úlohu, při které lze využít metody strojového a hlubokého učení. Kvalita vína je ovlivňována řadou faktorů, mezi které patří také jeho fyzikálně-chemické vlastnosti. Na základě naměřených hodnot těchto vlastností je možné vytvářet modely, které se snaží předpovědět výsledné hodnocení kvality vína. Jedná se o regresní úlohu, při níž model odhaduje číselnou hodnotu na základě vstupních dat.

Cílem tohoto semestrálního projektu je navrhnout, implementovat a experimentálně vyhodnotit vlastní neuronovou síť typu Multi-Layer Perceptron (MLP) a porovnat její výsledky s moderním předtrénovaným modelem TabPFN-2.5. Pro experimenty byla zvolena veřejně dostupná datová sada Wine Quality obsahující informace o červených a bílých vínech. Jako referenční metody jsou použity jednoduchý regresní model předpovídající průměrnou hodnotu a algoritmus K-Nearest Neighbors (KNN).

Součástí práce je příprava a analýza dat, hledání vhodných hyperparametrů neuronové sítě a provedení cílených experimentů zaměřených na vliv architektury modelu, množství trénovacích dat a kombinování predikcí více neuronových sítí. Pozornost je věnována také opakovatelnosti experimentů, vyhodnocení predikční chyby a porovnání výpočetní náročnosti jednotlivých přístupů. Cílem není pouze dosažení co nejnižší chyby predikce, ale také posouzení výhod, omezení a praktické využitelnosti zvolených metod.

Zdrojový kód projektu, experimentální notebook v prostředí Google Colab a související výsledky jsou dostupné ve veřejném repozitáři

GitHub: https://github.com/Domiann1/wine-quality-deep-learning.

1 Data a jejich předzpracování

Pro správné trénování a vyhodnocení modelů je nezbytné věnovat pozornost kvalitě a přípravě vstupních dat. Tato kapitola představuje použitou datovou sadu Wine Quality, její základní charakteristiky a výsledky průzkumné analýzy. Dále popisuje odstranění duplicit, rozdělení dat na trénovací, validační a testovací množinu a postup standardizace vstupních atributů. Jednotlivé kroky předzpracování byly navrženy s ohledem na omezení možného úniku informací mezi datovými množinami.

1.1 Popis datové sady

Pro experimenty byla použita veřejně dostupná datová sada Wine Quality z repozitáře UCI Machine Learning Repository [1]. Obsahuje fyzikálně-chemické vlastnosti červených a bílých portugalských vín a jejich výsledné hodnocení kvality. Původní data obsahovala 6 497 záznamů a 11 chemických atributů, například obsah alkoholu, kyselost, pH, hustotu nebo množství oxidu siřičitého.

Datové sady červených a bílých vín byly spojeny do jedné tabulky. Současně byl vytvořen binární atribut `wine_type`, kde hodnota 0 označuje červené a hodnota 1 bílé víno. Modely tak využívají celkem 12 vstupních atributů. Cílovou proměnnou je `quality`, představující číselné hodnocení vína. Úloha byla formulována jako regresní problém.

1.2 Explorační analýza dat

V rámci průzkumné analýzy byla ověřena úplnost dat, základní statistické charakteristiky, rozložení cílové proměnné a vztahy mezi jednotlivými atributy. V datové sadě nebyly nalezeny chybějící hodnoty. Hodnocení kvality nabývalo hodnot od 3 do 9, přičemž nejčastěji se vyskytovaly hodnoty 5 a 6. Krajní hodnocení byla zastoupena výrazně méně. Rozložení hodnocení v původní datové sadě je znázorněno na obrázku 1.

Bylo také identifikováno 1 177 přesných duplicit, které byly před rozdělením dat odstraněny. Výsledná datová sada obsahovala 5 320 unikátních záznamů. Nerovnoměrné zastoupení jednotlivých hodnocení představuje omezení při predikci méně častých hodnot kvality.

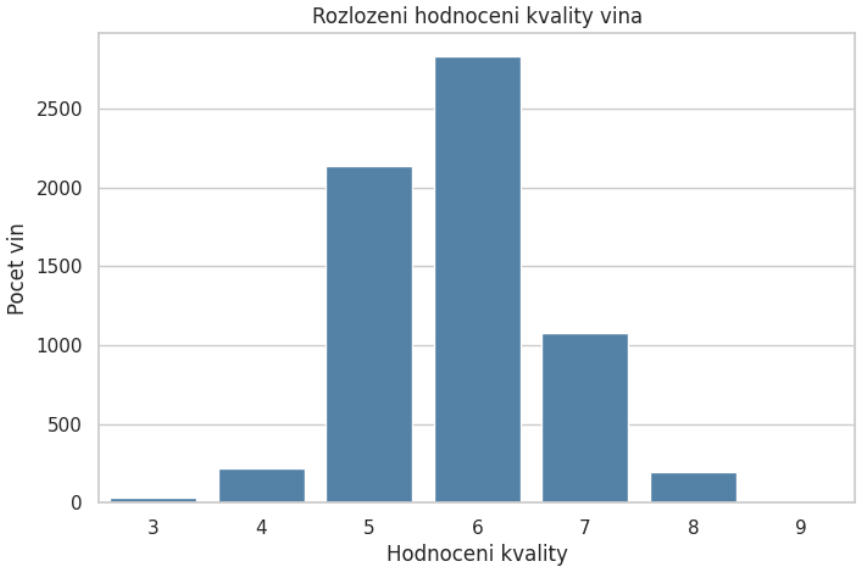
1.3 Rozdělení dat a standardizace

Po odstranění duplicit byla data náhodně rozdělena na trénovací (70 %), validační (15 %) a testovací množinu (15 %) s použitím náhodného semene 42. Trénovací množina obsahovala 3 724 vzorků, validační 798 a testovací rovněž 798 vzorků.

Pro numerické vstupní atributy byla provedena standardizace pomocí metody `StandardScaler`, která převádí hodnoty podle vztahu

$$z = \frac{x - \mu}{\sigma}, \tag{1}$$

kde x představuje původní hodnotu atributu, μ jeho průměr a σ směrodatnou odchylku. Parametry standardizace byly vypočteny výhradně z trénovací množiny a následně použity také pro validační a testovací data. Tím bylo zabráněno úniku informací z evaluačních dat do předzpracování. Binární atribut `wine_type` nebyl standardizován.



Obrázek 1: Rozložení hodnocení kvality vína v původní datové sadě před odstraněním duplicit.

2 Použité modely

Pro řešení regresní úlohy byly zvoleny čtyři přístupy s různou úrovní složitosti. Jednoduchý výchozí model a algoritmus KNN slouží jako referenční metody. Hlavní část experimentů je zaměřena na vlastní neuronovou síť MLP implementovanou v knihovně PyTorch a předtrénovaný model TabPFN-2.5. Jejich porovnání umožňuje posoudit přínos hlubokého učení oproti jednodušším metodám a rozdíly mezi učením modelu od začátku a využitím předtrénovaných vah.

2.1 Baseline a model KNN

Jako základní referenční metoda byl použit model `DummyRegressor` s nastavením `strategy=mean`. Tento model předpovídá pro všechny vstupy průměrnou hodnotu kvality vypočtenou z trénovací množiny. Slouží k ověření, zda složitější metody dokážou dosáhnout nižší predikční chyby než jednoduchý konstantní odhad.

Druhým referenčním přístupem byl algoritmus K-Nearest Neighbors (KNN), který odhaduje kvalitu vína na základě hodnot jeho nejbližších sousedů v prostoru vstupních atributů. Na validačních datech byly porovnány hodnoty $k \in \{3, 5, 7, 10, 15, 20, 30\}$. Pro další vyhodnocení byla vybrána hodnota $k = 30$, která dosáhla nejnižší validační chyby MAE.

2.2 Vlastní neuronová síť MLP

Vlastní regresní model byl implementován pomocí knihovny PyTorch [3] jako vícevrstvá dopředná neuronová síť (Multi-Layer Perceptron, MLP). Síť přijímá 12 vstupních atributů a vrací jednu spojitou hodnotu představující odhad kvality vína.

Počáteční architektura obsahovala dvě skryté vrstvy o velikostech 64 a 32 neuronů. V rámci experimentů byly následně porovnány také architektury 16–8 a 128–64. Jako finální varianta byla zvolena síť s architekturou 12–128–64–1, která obsahuje dvě skryté vrstvy s aktivační funkcí ReLU a lineární výstupní vrstvu.

Dopředný průchod sítí lze vyjádřit vztahem

$$\hat{y} = W_3 \,\mathrm{ReLU}\left(W_2 \,\mathrm{ReLU}(W_1 x + b_1) + b_2\right) + b_3, \tag{2}$$

kde x představuje vstupní vektor, W_i váhové matice, b_i vektory posunů a $\hat{y}$ výslednou predikci.

Finální síť byla trénována od náhodné inicializace vah. Pro zvýšení stability výsledků byly natrénovány tři samostatné modely s různými náhodnými semeny. Jejich predikce byly následně zprůměrovány, čímž vznikl soubor modelů (ensemble).

2.3 Předtrénovaný model TabPFN-2.5

Druhým hlavním přístupem byl model TabPFN-2.5 (Tabular Prior-Data Fitted Network), vycházející z rodiny předtrénovaných modelů TabPFN [2], určených pro práci s tabulkovými daty. Při použití na datové sadě Wine Quality tak nebylo nutné trénovat neuronovou síť od začátku.

Pro regresní úlohu byla použita implementace `TabPFNRegressor` s předtrénovaným modelem verze 2.5. Model byl přizpůsoben trénovacím datům pomocí metody `fit` a následně použit k predikci kvality vín ve validační a testovací množině. Na rozdíl od MLP byly pro TabPFN použity původní, nestandardizované vstupní atributy.

Hlavním cílem porovnání bylo ověřit, zda předtrénovaný model dosáhne lepších výsledků než vlastní neuronová síť, a posoudit rozdíly v jejich predikční kvalitě a výpočetní náročnosti.

3 Metodika trénování a experimentů

Experimentální část projektu byla zaměřena na systematické hledání vhodného nastavení neuronové sítě a vyhodnocení faktorů ovlivňujících přesnost predikce. Jednotlivé varianty byly porovnávány na stejné validační množině. Testovací data byla vyhrazena pro závěrečné vyhodnocení, aby nedocházelo k přizpůsobování modelů výsledkům testování.

3.1 Ztrátová funkce a optimalizace

Vlastní neuronová síť MLP byla trénována minimalizací střední kvadratické chyby (Mean Squared Error, MSE), definované vztahem

$$\mathrm{MSE} = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2, \tag{3}$$

kde n označuje počet vzorků, y_i skutečné hodnocení kvality vína a $\hat{y}_i$ predikci modelu. Pro aktualizaci vah byl použit optimalizátor Adam, který upravuje parametry neuronové sítě na základě gradientů ztrátové funkce.

Trénování probíhalo maximálně 1 000 epoch s využitím celé trénovací množiny při každém aktualizačním kroku. Pro omezení přeučení bylo použito předčasné zastavení (early stopping) s tolerancí 50 epoch bez zlepšení validační MSE. Po ukončení trénování byly obnoveny váhy modelu z epochy s nejnižší validační chybou.

Predikční kvalita byla vyhodnocována pomocí metrik MAE (Mean Absolute Error) a RMSE (Root Mean Squared Error):

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \tag{4}$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}. \tag{5}$$

Nižší hodnoty obou metrik představují přesnější predikce. MAE vyjadřuje průměrnou absolutní odchylku, zatímco RMSE výrazněji penalizuje větší chyby.

3.2 Hledání hyperparametrů

Hledání hyperparametrů probíhalo na validační množině. Nejprve byly porovnány tři rychlosti učení (learning rate): 0,001, 0,003 a 0,01. Cílem bylo ověřit, jak velikost kroku optimalizátoru ovlivňuje dosaženou chybu a průběh trénování.

Následně byly testovány tři architektury MLP se dvěma skrytými vrstvami: 16–8, 64–32 a 128–64 neuronů. Při jejich porovnávání byla použita rychlost učení 0,01. Jednotlivé konfigurace byly hodnoceny pomocí validačních metrik MAE a RMSE. Pro další experimenty byla zvolena architektura 128–64.

Tabulka 1: Přehled nastavení experimentů

Parametr	**Testované hodnoty**
Learning rate	0,001; 0,003; 0,01
Architektura MLP	16–8; 64–32; 128–64
Podíl trénovacích dat	25; 50; 75; 100 %
Náhodná semena	42; 123; 2026
Maximum epoch	1 000
Early stopping	50 epoch

3.3 Cílené experimenty a opakovatelnost

Pro ověření vlivu vybraných faktorů byly provedeny čtyři cílené experimenty:

1. **Rychlost učení:** Předpokladem bylo, že vhodně zvolená rychlost učení sníží predikční chybu a umožní efektivnější optimalizaci.

2. **Architektura MLP:** Byla ověřována hypotéza, že větší síť dosáhne nižší chyby než menší varianty, avšak za cenu vyšší výpočetní náročnosti.

3. **Množství trénovacích dat:** Byly použity podíly 25, 50, 75 a 100 % trénovací množiny. Předpokládalo se zlepšování predikcí s rostoucím počtem dostupných vzorků.

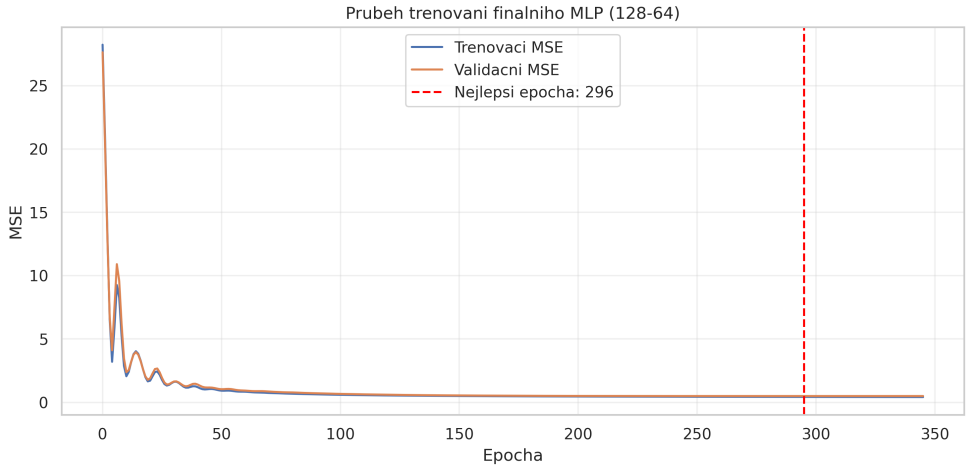
4. **Kombinování modelů:** Bylo zkoumáno, zda průměrování predikcí tří nezávisle inicializovaných sítí MLP sníží chybu oproti jednotlivým modelům.

Pro posouzení stability finální architektury byla provedena tři trénování s náhodnými semeny 42, 123 a 2026 při zachování stejného rozdělení dat. Výsledky byly shrnuty pomocí aritmetického průměru a výběrové směrodatné odchylky. Experiment s různým množstvím trénovacích dat byl proveden s jedním náhodným výběrem pro každou velikost, proto jeho výsledky představují orientační srovnání.

Finální ensemble MLP vznikl zprůměrováním predikcí tří samostatně natrénovaných sítí. Pro výsledný odhad platí

$$\hat{y}_{\text{ens}} = \frac{1}{3} \sum_{j=1}^{3} \hat{y}_j, \tag{6}$$

kde $\hat{y}_j$ označuje predikci j-té neuronové sítě.



Obrázek 2: Průběh trénovací a validační ztrátové funkce finálního modelu MLP s architekturou 128–64.

4 Výsledky a vyhodnocení

Tato kapitola shrnuje výsledky experimentů a porovnává predikční kvalitu jednotlivých modelů. Nejprve jsou vyhodnoceny dosažené chyby na testovacích datech a vliv vybraných hyperparametrů. Následuje posouzení stability modelů při opakovaném měření a porovnání jejich výpočetní náročnosti. Závěrečná část se věnuje analýze predikčních chyb.

4.1 Porovnání predikční kvality

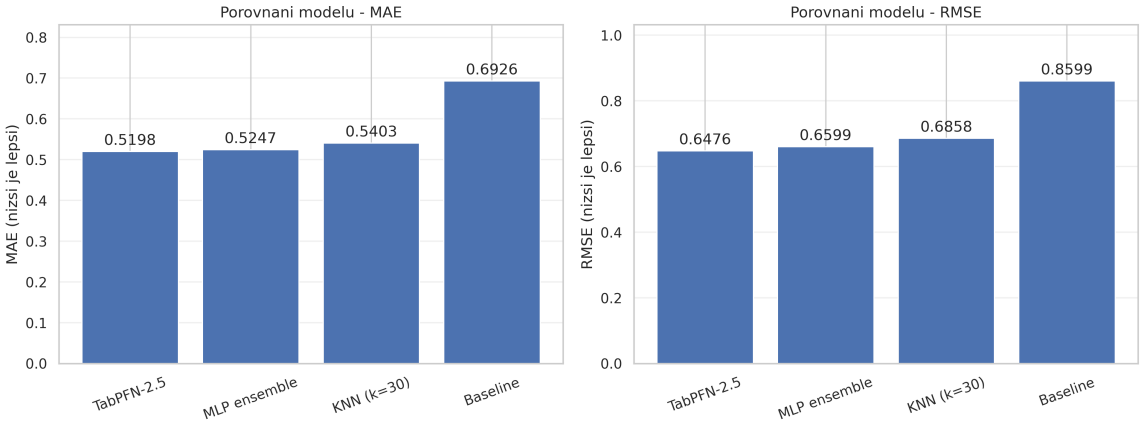
Závěrečné porovnání bylo provedeno na testovací množině obsahující 798 vzorků, která nebyla využívána k výběru hyperparametrů. Výsledky jednotlivých modelů uvádí tabulka 2.

Nejlepších výsledků dosáhl předtrénovaný TabPFN-2.5 s hodnotami MAE 0,5198 a RMSE 0,6476. Druhým nejpřesnějším přístupem byl soubor tří neuronových sítí MLP s MAE 0,5247. Oba přístupy překonaly model KNN i jednoduchý baseline.

Tabulka 2: Porovnání modelů na testovací množině

Model	**MAE**	**RMSE**
Baseline	0,6926	0,8599
KNN ($k = 30$)	0,5403	0,6858
MLP ensemble	0,5247	0,6599
TabPFN-2.5	**0,5198**	**0,6476**

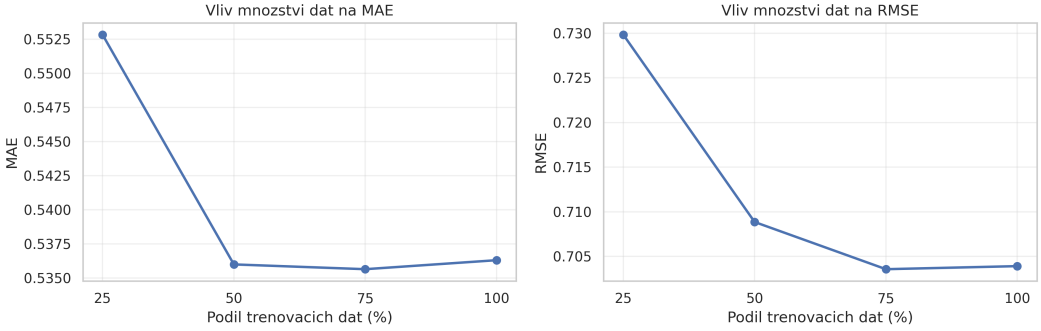
Rozdíl mezi TabPFN a MLP ensemble byl však poměrně malý, a proto nelze pouze z těchto hodnot vyvozovat statisticky významnou převahu jednoho modelu.



Obrázek 3: Porovnání testovacích metrik MAE a RMSE jednotlivých modelů.

Při ladění neuronové sítě bylo na validačních datech dosaženo nejnižší MAE při rychlosti učení 0,01. Z testovaných architektur byla nejúspěšnější varianta 128–64 neuronů s validační MAE 0,5361. Její výsledky byly lepší než u menších variant 16–8 (MAE 0,5575) a 64–32 (MAE 0,5453).

Experiment s množstvím trénovacích dat ukázal, že při použití 25 % vzorků dosahovala síť MAE 0,5528. Při využití 75 % dat se chyba snížila na 0,5356. Při použití celé trénovací množiny byla MAE 0,5363. Výsledky tedy naznačují výraznější přínos přidávání dat v počáteční fázi, zatímco mezi 75 a 100 % dat byl rozdíl zanedbatelný. Jelikož byly podmnožiny vytvořeny jedním náhodným výběrem, nelze z experimentu vyvozovat obecně platnou závislost.



Obrázek 4: Vliv množství trénovacích dat na validační chybu modelu MLP.

4.2 Statistické vyhodnocení

Stabilita finální architektury MLP byla posouzena pomocí tří nezávislých trénování s různými náhodnými inicializacemi. Stejná množina náhodných semen byla využita také při opakovaném vyhodnocení TabPFN. Statistické shrnutí výsledků na validační množině uvádí tabulka 3.

Tabulka 3: Stabilita modelů na validačních datech (průměr ± směrodatná odchylka, $n = 3$)

Model	**MAE**	**RMSE**
MLP 128–64	$0{,}5344 \pm 0{,}0017$	$0{,}7001 \pm 0{,}0042$
TabPFN-2.5	$0{,}5337 \pm 0{,}0002$	$0{,}6855 \pm 0{,}0004$

U modelu MLP byla mezi jednotlivými běhy pozorována pouze malá variabilita výsledků. TabPFN dosahoval rovněž stabilních hodnot. Nízké směrodatné odchylky naznačují opakovatelnost dosažených výsledků za daných experimentálních podmínek. Vzhledem k pouhým třem opakováním však statistické závěry zůstávají omezené.

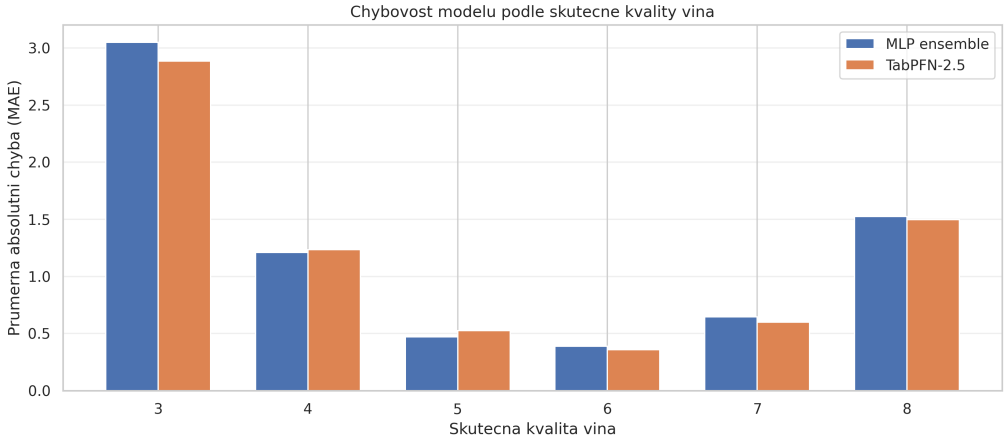
4.3 Výpočetní náročnost a analýza chyb

Experimenty byly prováděny v prostředí Google Colab s grafickou kartou NVIDIA Tesla T4. Vlastní síť MLP s architekturou 12–128–64–1 obsahovala 9 985 trénovatelných parametrů. Soubor tří sítí tak zahrnoval celkem 29 955 parametrů, zatímco model TabPFN obsahoval přibližně 10,19 milionu parametrů.

Průměrná doba trénování jedné finální MLP činila 2,184 s a celkový čas trénování tří sítí byl 6,552 s. U TabPFN byla naměřena průměrná doba přizpůsobení trénovacím datům 0,325 s. Tento čas nezahrnuje původní předtrénování modelu, a proto není přímo srovnatelný s učením vlastní MLP od začátku.

Při predikci celé testovací množiny 798 vzorků trvala inference MLP ensemble průměrně 1,094 ms, zatímco TabPFN potřeboval 3 062,874 ms. Předtrénovaný model tedy dosahoval mírně lepší přesnosti, avšak za cenu výrazně pomalejší inference v naměřeném prostředí.

Analýza absolutních chyb podle skutečné kvality ukázala, že modely dosahovaly nižších chyb zejména u běžně zastoupených hodnocení 5 a 6. Naopak u méně častých krajních hodnocení byly chyby výrazně vyšší. Tento výsledek souvisí s nerovnoměrným rozložením cílové proměnné a představuje omezení praktického využití modelů při hodnocení méně obvyklých vín.



Obrázek 5: Průměrná absolutní chyba predikce podle skutečného hodnocení kvality vína.

4.4 Využití generativní umělé inteligence

Při realizaci projektu byla využita generativní umělá inteligence jako podpůrný nástroj při tvorbě a úpravách programového kódu, řešení technických problémů a přípravě dokumentace. Navržené postupy byly kontrolovány a ověřovány spouštěním programu, kontrolou implementace a vyhodnocováním výsledků experimentů.

5 Diskuse

Výsledky experimentů ukázaly, že metody strojového a hlubokého učení dokážou předpovídat kvalitu vína na základě jeho fyzikálně-chemických vlastností s nižší chybou než jednoduchý výchozí model. Nejlepší predikční výsledky dosáhl předtrénovaný TabPFN-2.5, který na testovací množině dosáhl MAE 0,5198. Vlastní neuronová síť MLP v podobě souboru tří modelů dosáhla velmi podobné hodnoty MAE 0,5247.

Přestože TabPFN dosáhl nejnižší chyby, jeho výhoda oproti MLP ensemble byla malá. Výsledky proto neprokazují jednoznačnou statistickou převahu předtrénovaného modelu. Významným rozdílem byla výpočetní náročnost. Vlastní MLP poskytovala výrazně rychlejší inference, zatímco TabPFN vyžadoval delší čas pro vytvoření predikcí. Při výběru modelu pro praktické použití je proto vhodné zohlednit nejen přesnost, ale také rychlost a dostupné výpočetní prostředky.

Experimenty s hyperparametry potvrdily význam správného nastavení neuronové sítě. Z testovaných variant dosáhla nejlepších validačních výsledků architektura 128–64. Při zvyšování množství trénovacích dat docházelo zpravidla ke snižování chyby, avšak mezi využitím 75 a 100 % dat nebylo pozorováno další výrazné zlepšení. Opakovaná trénování s různými náhodnými semeny zároveň ukázala relativně nízkou variabilitu výsledků.

Hlavním omezením práce je použití jediné datové sady s nerovnoměrným zastoupením jednotlivých hodnocení kvality. Modely dosahovaly vyšších chyb zejména u méně častých krajních hodnot, pro které bylo k dispozici méně trénovacích příkladů. Samotné hodnocení kvality vína je navíc do určité míry subjektivní a fyzikálně-chemické vlastnosti nemusí zachycovat všechny faktory ovlivňující jeho výsledné posouzení.

Dalším omezením je malý počet opakovaných měření a omezený rozsah testovaných hyperparametrů. Výsledky byly získány na jediném rozdělení dat a jejich zobecnitelnost na jiné datové sady nebyla ověřena. V navazující práci by proto bylo vhodné využít opakovanou křížovou validaci, rozšířit hledání hyperparametrů a ověřit modely také na dalších regresních úlohách.

Závěr

Cílem semestrálního projektu bylo navrhnout, implementovat a experimentálně vyhodnotit model hlubokého učení pro predikci kvality vína na základě jeho fyzikálně-chemických vlastností. Součástí práce bylo porovnání vlastní neuronové sítě MLP s moderním předtrénovaným modelem TabPFN-2.5 a jednoduššími referenčními metodami.

V rámci projektu byla provedena analýza a příprava datové sady Wine Quality, implementace jednotlivých modelů, ladění hyperparametrů a několik cílených experimentů. Byl zkoumán zejména vliv rychlosti učení, architektury neuronové sítě a množství trénovacích dat. Stabilita výsledků byla ověřena pomocí opakovaných trénování s různými náhodnými inicializacemi.

Nejnižší predikční chyby na testovací množině dosáhl předtrénovaný model TabPFN-2.5 s hodnotami MAE 0,5198 a RMSE 0,6476. Velmi podobných výsledků dosáhl také soubor tří vlastních neuronových sítí MLP s hodnotami MAE 0,5247 a RMSE 0,6599. Oba přístupy překonaly referenční modely baseline a KNN.

Výsledky ukázaly, že předtrénovaný model může dosáhnout mírně vyšší predikční přesnosti, zatímco vlastní neuronová síť nabízí výrazně rychlejší inference. Volba vhodného přístupu proto závisí nejen na přesnosti, ale také na výpočetních požadavcích.

Stanovený cíl projektu byl splněn. Práce poskytla experimentální srovnání vlastního a předtrénovaného modelu hlubokého učení a ukázala význam systematického ladění a vyhodnocování modelů při řešení regresních úloh nad tabulkovými daty.

Literatura

[1] Cortez, P., Cerdeira, A., Almeida, F., Matos, T. a Reis, J. (2009). *Wine Quality*. UCI Machine Learning Repository. https://doi.org/10.24432/C56S3T

[2] Hollmann, N., Müller, S., Purucker, L. a kol. (2025). *Accurate predictions on small data with a tabular foundation model*. Nature, 637, 319–326. https://doi.org/10.1038/s41586-024-08328-6

[3] Paszke, A., Gross, S., Massa, F. a kol. (2019). *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. Advances in Neural Information Processing Systems, 32. https://arxiv.org/abs/1912.01703

Seznam obrázků

1 Rozložení hodnocení kvality vína v původní datové sadě před odstraněním duplicit. 5
2 Průběh trénovací a validační ztrátové funkce finálního modelu MLP s architekturou 128–64. 8
3 Porovnání testovacích metrik MAE a RMSE jednotlivých modelů. 9
4 Vliv množství trénovacích dat na validační chybu modelu MLP. 9
5 Průměrná absolutní chyba predikce podle skutečného hodnocení kvality vína. . . 10

Seznam tabulek

1 Přehled nastavení experimentů 7
2 Porovnání modelů na testovací množině 9
3 Stabilita modelů na validačních datech (průměr ± směrodatná odchylka, $n = 3$) . 10